

Harvard-GDP 多任务学习实验总结

进展预测主任务、RNFLT-only 检测辅助与 Backbone 鲁棒性

核心结论：正式模型 MultiTask-Full 将青光眼检测限定为 RNFLT-only 辅助任务，MD/TD 进展预测使用 RNFLT+GIN52。与严格匹配的单任务模型相比，该结构在核心实验中将 MD AUROC 提高 0.1902、TD AUROC 提高 0.0253；在四种 RNFLT backbone 上，MD AUROC 均稳定提高，说明多任务学习对 MD 进展预测的帮助具有较好的 backbone 鲁棒性。综合 MD、TD 两个终点，最终保留 EfficientNet-V2-S 版本的 MultiTask-Full。

1 实验目的

本组实验集中回答两个问题：

1. 青光眼检测作为 RNFLT-only 辅助任务，能否帮助 MD 和 TD 进展预测，而不引入 TDS 标签捷径？
2. 如果更换 RNFLT backbone，多任务收益是否仍然存在，还是仅对 EfficientNet-V2-S 有效？

报告将**严格匹配的单任务-多任务比较**作为主要证据，将共享层消融和 TDS 检测审计作为解释性证据。后续大量复杂训练策略只在结论中简要说明，不再逐批罗列，避免掩盖主线。

2 数据与评价方式

数据包含 1,000 名受试者。检测标签对全部样本有效；MD 和 TD 进展标签各只有 500 个有效样本，其余 500 个缺失标签均通过独立 label mask 排除，绝不置为阴性。

表 1: 三个任务的标签覆盖与类别分布。

任务	有效标签	阳性	阴性	缺失并掩码
青光眼检测	1,000	443	557	0
MD 进展	500	13	487	500
TD 进展	500	148	352	500

所有主要实验均采用受试者级五折交叉验证和 seed 42/43/44。每个 seed 先合并五个互斥测试 fold，得到完整 OOF 预测，再对三个 seed 的 OOF 指标计算均值与样本标准差。因此，三个 seed 是同一批受试者的重复训练结果，不是三倍独立样本。

指标说明。AUROC 衡量模型对阳性和阴性的整体排序能力；AUPRC 更关注阳性类别，在类别不平衡时更有解释价值。本文主结论以 AUROC 和 AUPRC 为主。MD 只有 13 个阳性，因此其 AUPRC 和阈值相关指标波动较大，不据此宣称统计或临床显著性。

3 模型结构与实验配置

3.1 正式模型：MultiTask-Full




图 1: 正式 MultiTask-Full 结构。检测在多模态融合之前分支；MD 与 TD 共享融合后的进展 trunk，但使用独立 head 和标签掩码。

RNFLT 分支使用已经验证完成的 corrected FNO，不在本实验中重新设计。TDS 分支将 52 个真实视野测量点直接作为图节点，通过固定二维坐标、8 邻域图和两层 GIN 得到 128 维表征；它不把 TDS 转成 8×9 图像，也不上采样到 224×224 。检测 head 只读取 RNFLT 特征；MD 和 TD 则读取拼接后的 RNFLT+GIN52 特征。

表 3 与表 2 逐行对应，补全了每个已定义配置的实际 OOF 结果。单任务配置只训练一个任务，因此其余任务记为“-”，并非结果缺失。

4 主要多任务结果

表 4 来自同一批严格匹配实验：单任务和 MultiTask-Full 使用相同输入处理、编码器、数据划分和训练 seed，仅改变是否进行多任务共享训练。

- **MD 是最明确的受益任务。** AUROC 从 0.6831 提升至 0.8734，增加 0.1902；AUPRC 从 0.0853 提升至 0.1256。
- **TD 也获得一致的中等提升。** AUROC 增加 0.0253，AUPRC 增加 0.0494。
- **检测只承担辅助监督角色。** 其 AUROC/AUPRC 小幅提高约 0.009，但本研究不以检测性能超过专用检测模型为目标。

因此，这组实验支持的直接结论是：在完全匹配的训练条件下，RNFLT-only 检测辅助与共享进展表示能够同时改善 MD 和 TD 进展预测，其中 MD 收益最明显。

表 2: 报告中各实验配置的确切含义。

配置名称	输入与共享方式	该配置回答的问题
single_detection_matched	RNFLT → corrected FNO → RNFLT 编码器 → 检测 head	检测单任务匹配对照。
single_md_gin52	RNFLT+GIN52, 只训练 MD head	MD 单任务匹配对照。
single_td_gin52	RNFLT+GIN52, 只训练 TD head	TD 单任务匹配对照。
recommended_branch_before_fusion	检测从 RNFLT 融合前分支; MD/TD 共享 RNFLT 编码器、GIN52 与进展 trunk	正式 MultiTask-Full; 检验 RNFLT-only 检测辅助是否改善进展预测。
separate_progression_trunks	编码器共享, 但 MD/TD 使用独立进展 trunk	检验 MD 与 TD 是否需要共享融合后表示。
task_specific_rnflt_projection	RNFLT 编码器共享, 投影层按任务拆分	检验共享 RNFLT 投影是否限制任务差异。
任务均衡交替更新	网络结构不变, 改变三个任务的更新频率	检验简单任务均衡训练是否优于同时更新。
预训练后分别微调	先多任务预训练, 再冻结编码器并分别微调三个任务	检验分任务微调; 最终会得到多个模型。

表 3: 表 2 中全部配置的实际 OOF 结果。每个数值均为三个 seed 分别合并五折 OOF 后的均值 ± 样本标准差; 单元格依次报告 AUROC / AUPRC。粗体为各多任务配置中的列最优值。

配置名称	检测 AUROC / AUPRC	MD AUROC / AUPRC	TD AUROC / AUPRC
single_detection_matched	0.8155 ± 0.0150 / 0.8167 ± 0.0110	–	–
single_md_gin52	–	0.6831 ± 0.0734 / 0.0853 ± 0.0384	–
single_td_gin52	–	–	0.7676 ± 0.0087 / 0.5849 ± 0.0197
recommended_branch_before_fusion (MultiTask-Full)	0.8247 ± 0.0080 / 0.8257 ± 0.0070	0.8734 ± 0.0377 / 0.1256 ± 0.0301	0.7929 ± 0.0080 / 0.6343 ± 0.0160
separate_progression_trunks	0.8152 ± 0.0046 / 0.8144 ± 0.0133	0.7114 ± 0.0822 / 0.0778 ± 0.0122	0.7857 ± 0.0048 / 0.6263 ± 0.0046
task_specific_rnflt_projection	0.8270 ± 0.0052 / 0.8268 ± 0.0018	0.8422 ± 0.0089 / 0.0923 ± 0.0067	0.7730 ± 0.0034 / 0.6292 ± 0.0048
任务均衡交替更新	0.8257 ± 0.0076 / 0.8250 ± 0.0029	0.8509 ± 0.0227 / 0.1233 ± 0.0243	0.7905 ± 0.0054 / 0.6313 ± 0.0040
预训练后冻结编码器并分别微调	0.8276 ± 0.0034 / 0.8266 ± 0.0079	0.8568 ± 0.0265 / 0.1357 ± 0.0196	0.7972 ± 0.0058 / 0.6302 ± 0.0078

表 4: 核心结构实验: MultiTask-Full 与严格匹配单任务模型的 OOF 比较。数值为三个 seed 的 OOF 均值 ± 样本标准差; Δ 表示多任务减单任务。

任务	指标	匹配单任务	MultiTask-Full	Δ
检测	AUROC	0.8155 ± 0.0150	0.8247 ± 0.0080	+0.0092
	AUPRC	0.8167 ± 0.0110	0.8257 ± 0.0070	+0.0090
MD 进展	AUROC	0.6831 ± 0.0734	0.8734 ± 0.0377	+0.1902
	AUPRC	0.0853 ± 0.0384	0.1256 ± 0.0301	+0.0404
TD 进展	AUROC	0.7676 ± 0.0087	0.7929 ± 0.0080	+0.0253
	AUPRC	0.5849 ± 0.0197	0.6343 ± 0.0160	+0.0494

数值口径提示。本节是最初的核心结构实验矩阵；下一节是独立完成的 240-run backbone 鲁棒性矩阵。两组实验使用相同 OOF 汇总原则，但属于独立训练复现，因此绝对数值略有差异。判断方法是否有效应在各自矩阵内部与匹配单任务模型比较，不能跨表直接相减。

5 不同 Backbone 下的结果

Backbone 实验固定 corrected FNO、GIN52、融合方式、数据划分和训练策略，仅替换 RNFLT 编码器。每种 backbone 均包含匹配的单任务模型与 MultiTask-Full，共计 $4 \times 2 \times 3 \times 5 = 120$ 个 MD 运行和 120 个 TD 运行。

表 5: MD 进展：不同 RNFLT backbone 下的匹配单任务与 MultiTask-Full 比较。

Backbone	单任务 AUROC	多任务 AUROC	Δ	单任务 AUPRC	多任务 AUPRC	Δ
EfficientNet-V2-S	0.7044	0.8760	+0.1716	0.1051	0.1242	+0.0191
ResNet-50	0.5840	0.8274	+0.2434	0.0412	0.1246	+0.0834
ConvNeXt-T	0.6412	0.8562	+0.2150	0.0550	0.1932	+0.1382
Swin-B	0.6601	0.8428	+0.1828	0.0549	0.1294	+0.0745

表 6: TD 进展：不同 RNFLT backbone 下的匹配单任务与 MultiTask-Full 比较。

Backbone	单任务 AUROC	多任务 AUROC	Δ	单任务 AUPRC	多任务 AUPRC	Δ
EfficientNet-V2-S	0.7749	0.8004	+0.0255	0.5983	0.6372	+0.0389
ResNet-50	0.7318	0.7723	+0.0405	0.5215	0.6134	+0.0919
ConvNeXt-T	0.7677	0.7767	+0.0091	0.6193	0.6109	-0.0085
Swin-B	0.7613	0.7735	+0.0122	0.5896	0.5918	+0.0021




图 2: 不同 RNFLT backbone 下，MultiTask-Full 相对匹配单任务模型的 AUROC/AUPRC 变化。正值表示多任务模型更好。

5.1 Backbone 结果如何理解

1. **MD 收益具有较强鲁棒性。**四种 backbone 的 AUROC 均提高，增益范围为 0.1716–0.2434；四种 backbone 的平均 AUPRC 也全部提高。这是多任务方法有效的最强稳定性证据。
2. **TD 收益较小并依赖 backbone。**EfficientNet-V2-S 与 ResNet-50 同时改善 AUROC 和 AUPRC；ConvNeXt-T 的 AUROC 提高 0.0091，但 AUPRC 下降 0.0085；Swin-B 的 AUPRC 仅提高 0.0021。
3. **EfficientNet-V2-S 是最终主模型。**它取得最高的 TD AUROC/AUPRC (0.8004/0.6372)，同时保持很强的 MD AUROC (0.8760)，在两个进展终点之间最均衡。
4. **ConvNeXt-T 是 MD 的补充结果。**其 MD AUPRC 最高 (0.1932)，但 TD AUPRC 下降，因此不能替代最终主模型。

6 核心结构消融

表 7: 共享结构与训练策略消融。前四行属于核心结构比较；后两行是补充训练策略。

配置	MD AUROC	MD AUPRC	TD AUROC	TD AUPRC
匹配单任务模型	0.6831	0.0853	0.7676	0.5849
MultiTask-Full	0.8734	0.1256	0.7929	0.6343
独立 MD/TD 进展 trunk	0.7114	0.0778	0.7857	0.6263
任务特异 RNFLT 投影	0.8422	0.0923	0.7730	0.6292
任务均衡交替更新	0.8509	0.1233	0.7905	0.6313
预训练后冻结编码器并分别微调	0.8568	0.1357	0.7972	0.6302

消融结果说明：

- 将 MD 与 TD 的进展 trunk 分开后，MD AUROC 从 0.8734 降至 0.7114，说明**共享进展表示是正式结构的关键部分**。
- 改用任务特异 RNFLT 投影没有获得联合收益，且 TD AUROC 明显下降，因此保留共享投影更合理。
- 任务均衡交替更新、预训练后分别微调等策略可以改善个别指标，但没有同时超过 MultiTask-Full 的全部主要指标；后者还会产生多个独立模型，不符合单模型部署目标。

7 检测任务的捷径审计

TDS-only 检测和 RNFLT+TDS 检测均接近 0.998 AUROC；而从融合检测器中移除 TDS 后，AUROC 降至 0.4958。这说明极高的检测性能主要来自 TDS 与检测标签之间的近确定性关系，而不是可推广的多模态互补信息。因此：

- 正式检测 head 必须只使用 RNFLT；
- TDS-fed 检测结果只能作为捷径诊断，不能进入有效模型排行榜；

表 8: 青光眼检测的 TDS 标签捷径审计。接近完美的 TDS-fed 结果是诊断证据，不是可用模型性能。

检测输入/诊断设置	AUROC	统计口径	解释
RNFLT-only, 无 FNO	0.8399	seed 级 OOF 均值	有效 RNFLT 检测对照。
RNFLT-only, corrected FNO	0.8410	seed 级 OOF 均值	有效 RNFLT 检测候选。
RNFLT+TDS	0.9979	seed 级 OOF 均值	TDS 进入检测后出现近完美结果。
TDS-only	0.9981	seed 级 OOF 均值	仅用 TDS 即可近乎重建检测标签。
融合模型移除 TDS	0.4958	显式输入消融的逐 fold 均值	移除 TDS 后降至随机水平，确认捷径来源。

- MultiTask-Full 在融合前分出检测 head，正是为了满足这一安全约束。

8 最终结论

1. **多任务方法有效。**严格匹配实验中，MultiTask-Full 同时提高 MD 和 TD，尤其显著改善 MD 排序能力。
2. **正式结构已经明确。**检测使用 RNFLT-only；MD/TD 使用 RNFLT+GIN52；三个任务共享 corrected FNO 与 RNFLT 编码器，MD/TD 进一步共享进展 trunk，并保留三个独立输出 head 和独立 label mask。
3. **方法具有 backbone 鲁棒性，但不同终点表现不完全相同。**MD 在四种 backbone 上均稳定受益；TD 最适合 EfficientNet-V2-S 或 ResNet-50。
4. **最终选择 EfficientNet-V2-S MultiTask-Full。**该模型在 MD 和 TD 之间取得最均衡的综合性能，也是后续论文主结果与方法描述应统一采用的版本。

结论边界：MD 进展只有 13 个阳性受试者，当前结果证明的是内部五折 OOF 条件下稳定的排序性能提升，尚不能证明外部临床泛化或统计显著性。下一步最有价值的验证是增加 MD 阳性样本并使用独立外部队列，而不是继续堆叠更复杂的多任务模块。